Το Δίκτυο Multi-Layer Perceptron και ο Κανόνας Back-Propagation

Κώστας Διαμαντάρας

Τμήμα Πληροφορικής

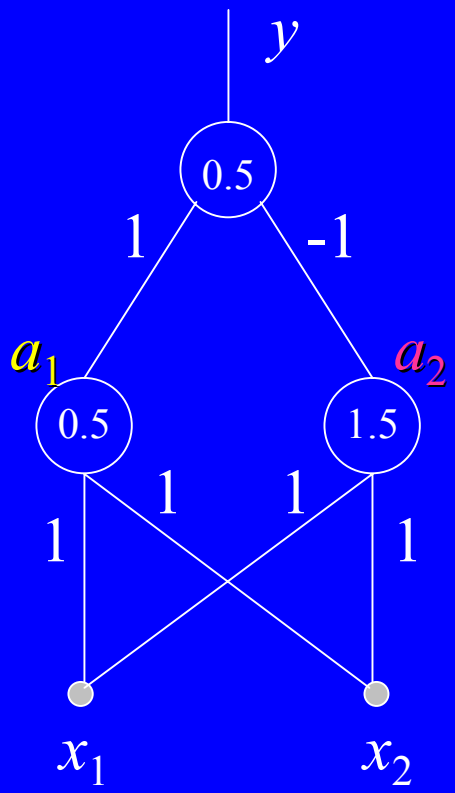
ΤΕΙ Θεσσαλονίκης

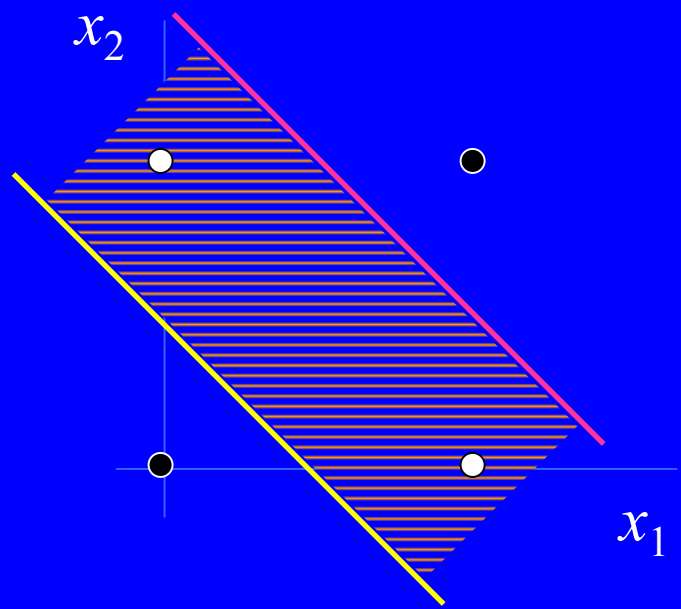
Το Πρόβλημα XOR

- Περιορισμένες δυνατότητες Perceptron (=1 νευρώνας). Πχ. Αδυναμία λύσης απλού προβλήματος XOR:

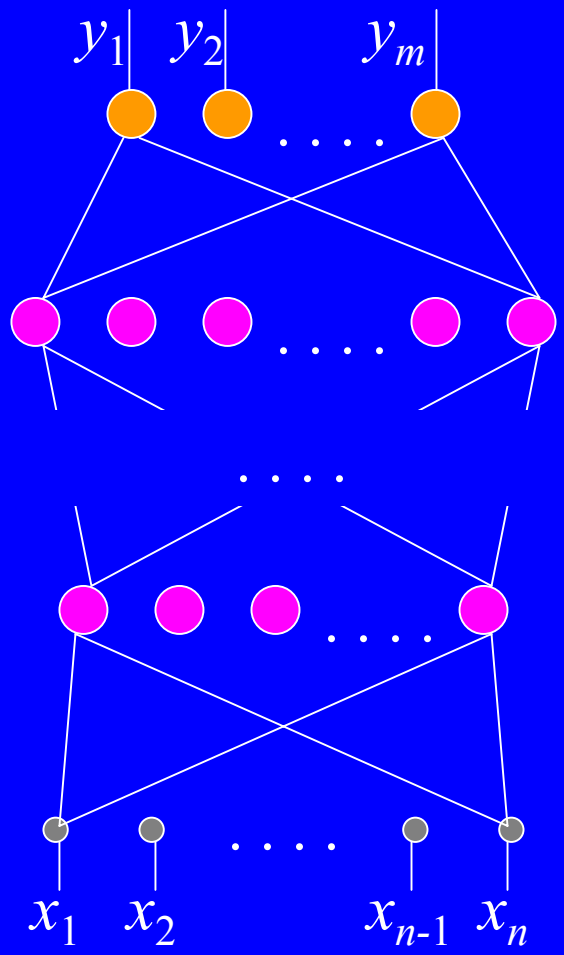
x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	0

Λύση του XOR με MLP





Γενική Τοπολογία Δικτύου MLP



Στρώμα Εξόδου

Κρυφό Στρώμα N

. . . .

Κρυφό Στρώμα 1

Στρώμα Εισόδου

Συνάρτηση Ενεργοποίησης



Δυαδική

Μη παραγωγίσιμη



Συνεχείς τιμές

Παραγωγίσιμη

Δυνατότητες Δδικτύων MLP (1)

- **Θεώρημα**

Έστω f = σιγμοειδής και $\phi(x_1, x_2, ..., x_p)$ *οποιαδήποτε συνεχής συνάρτηση p μεταβλητών ορισμένη στον μοναδιαίο κύβο* $I_p = [0,1]^p$. *Τότε υπάρχει ακέραιος M και κάποιες τιμές των παραμέτρων* α_i, w_{ij}, θ_i, *έτσι ώστε η συνάρτηση*

$$\phi(x_1, x_2, \cdots, x_n) = \sum_{i=1}^{M} \alpha_i f\left(\sum_{j=1}^{p} w_{ij} x_j + \theta_i\right)$$

προσεγγίζει την $\phi(x_1, x_2, ..., x_p)$ *με σφάλμα μικρότερο του ε για* όλες τις τιμές $\{x_1, x_2, ..., x_p\} \in I_p$ *και για οποιοδήποτε* $\varepsilon > 0$.

Δυνατότητες Δικτύων MLP (2)

Με απλά λόγια: (Ιδιότητα *Universal Approximator*)

- Ένα δίκτυο δύο στρωμάτων μπορεί να προσεγγίσει όσο καλά επιθυμούμε οποιαδήποτε συνεχή συνάρτηση

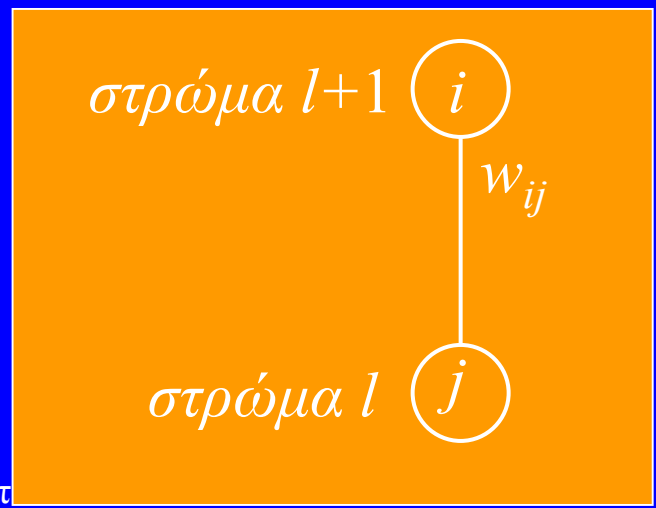
  – Οι νευρώνες του κρυφού στρώματος έχουν τη σιγμοειδή συνάρτηση ενεργοποίησης
  – Ο νευρώνας εξόδου έχει τη γραμμική συνάρτηση ενεργοποίησης

Δυνατότητες Δικτύων MLP (3)

- Όσο πιο πολύπλοκη είναι η συνάρτηση που επιθυμούμε να προσεγγίσουμε τόσο περισσότερους κρυφούς νευρώνες θέλουμε
- Δύο στρώματα αρκούν
- Universal Approximator : ισχύει και για συναρτήσεις πολλών εξόδων

Συμβολισμοί

- $N(l)$: πλήθος νευρώνων στο στρώμα l
- $a_i(l)$: έξοδος του νευρώνα i στρώμα l
- x_i : είσοδοι του δικτύου (μηδενικό στρώμα)
- y_i : έξοδοι του τελευταίου στρώματος
- w_{ij} : συναπτικό βάρος από νευρώνα i σε j



Ανάκληση

Είσοδοι: $a_1(0) = x_1, a_2(0) = x_2, \ldots, a_{N(0)}(0) = x_{N(0)}$

/* 0 = στρώμα εισόδου, L = στρώμα εξόδου */

Έξοδοι: $y_1 = a_1(L), y_2 = a_2(L), \ldots, y_{N(L)}(L) = a_{N(L)}(L)$

Για κάθε στρώμα $l = 1, \ldots, L$ {

Για κάθε νευρώνα $i = 1, \ldots, N(l)$ {

$$a_i(l) = f\left(\sum_{j=1}^{N(l-1)} w_{ij}(l)\, a_j(l-1) + w_{i0}(l)\right)$$

}

}

Εκπαίδευση

Κανόνας Back-Propagation

- Μάθηση με επίβλεψη
- $p = 1, \ldots, P$ ζεύγη {εισόδων/στόχων}
- Διάνυσμα στόχων $\mathbf{d}^{(p)} = [d_1^{(p)}, \cdots, d_m^{(p)}]^T$
- Διάνυσμα εισόδου $\mathbf{x}^{(p)} = [x_1^{(p)}, \cdots, x_n^{(p)}]^T$
- Διάνυσμα εξόδου $\mathbf{y}^{(p)} = [y_1^{(p)}, \cdots, y_m^{(p)}]^T$

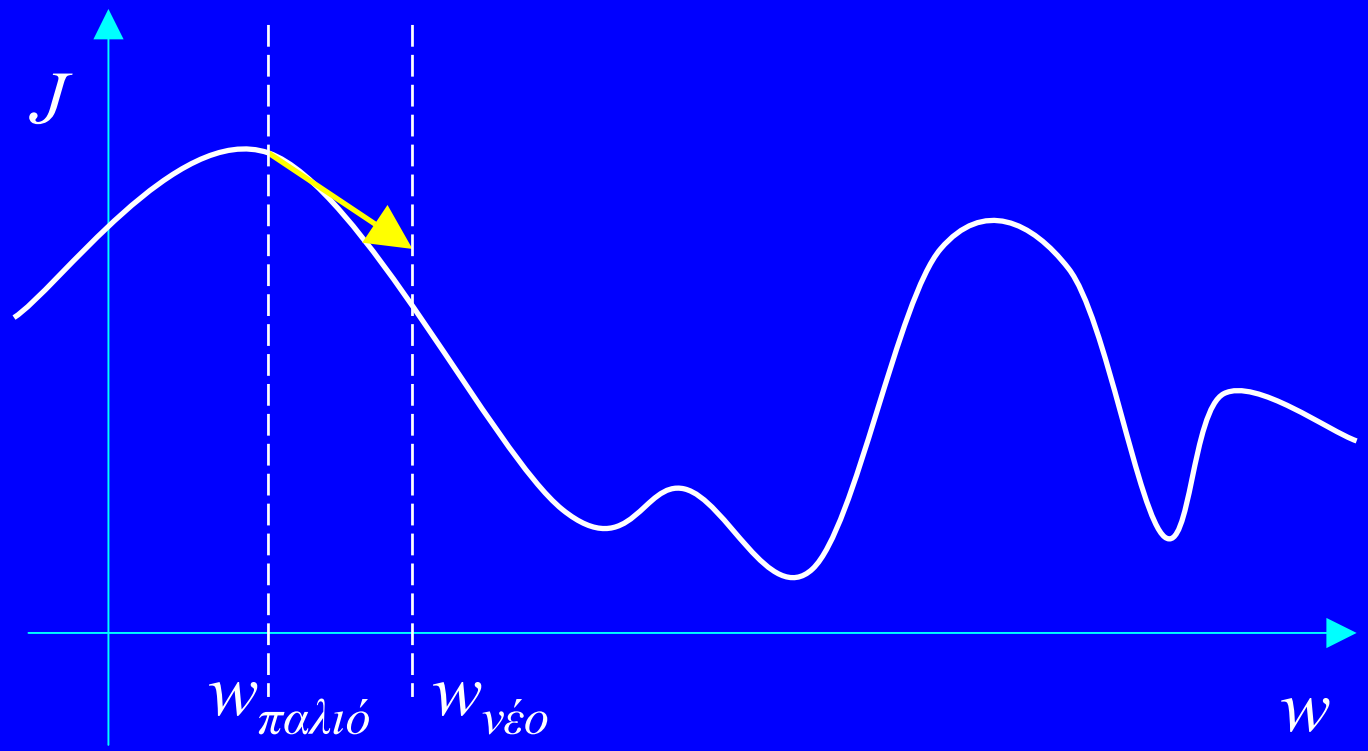
Back-propagation

- Κριτήριο μάθησης: ελαχιστοποίηση του μέσου τετραγωνικού σφάλματος για όλα τα πρότυπα (P το πλήθος)

$$J = \frac{1}{P}\sum_{p=1}^{P}\left\|\mathbf{d}^{(p)} - \mathbf{y}^{(p)}\right\|^2 = \frac{1}{P}\sum_{p=1}^{P}\sum_{i=1}^{m}[d_i^{(p)} - y_i^{(p)}]^2$$

- Μέθοδος βελτιστοποίησης: Κατάβαση Δυναμικού

Κατάβαση Δυναμικού (1)



Κατάβαση Δυναμικού (2)

- Παραγώγιση του κόστους ως προς τα συναπτικά βάρη

$$w_{ij}(k+1) - w_{ij}(k) = -\beta \frac{\partial J}{\partial w_{ij}(k)}$$

$$w_{ij}(k+1) = w_{ij}(k) - \beta \frac{\partial J}{\partial w_{ij}(k)}$$

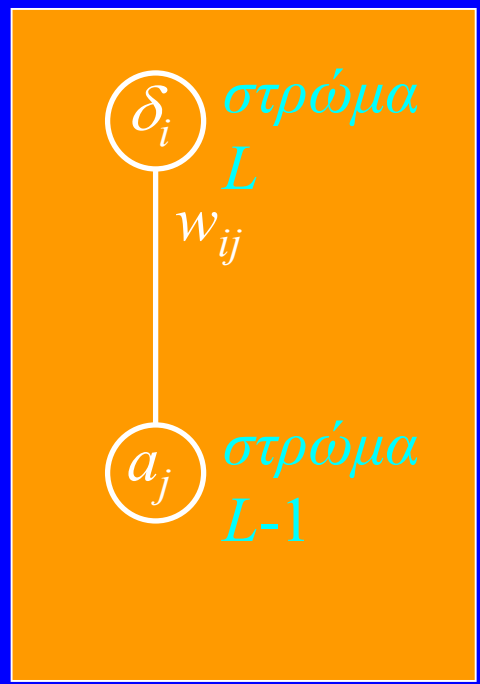
β = βήμα εκπαίδευσης = μικρή θετική τιμή

Ο Κανόνας BP

- Για το εξωτερικό στρώμα L

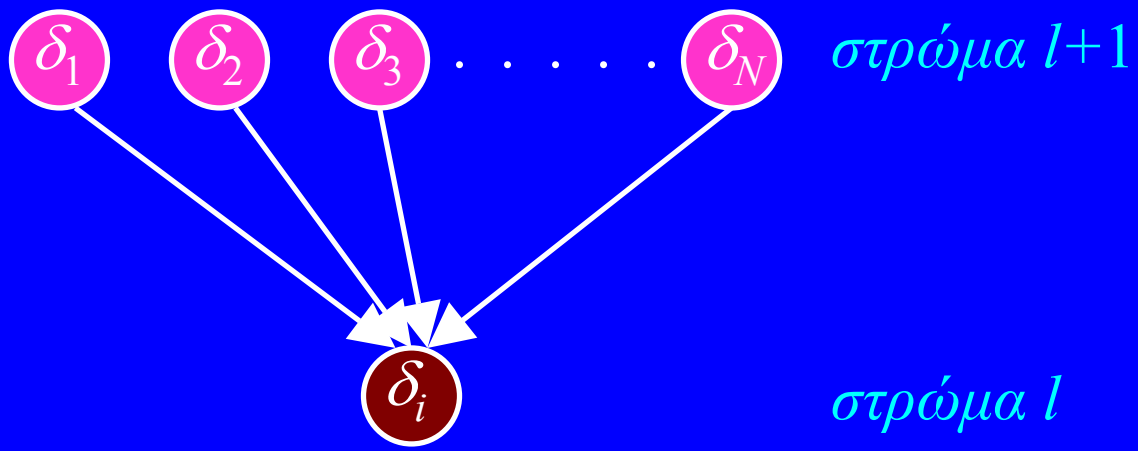
$$w_{ij}(k+1) = w_{ij}(k) + \beta\, \delta_i^{(k)}\, a_j^{(k)}$$
$$i = 1, \ldots, N(L)$$
$$j = 0, 1, \ldots, N(L-1)$$

$$\delta_i^{(k)} = (d_i^{(k)} - y_i^{(k)}) f'(u_i^{(k)})$$



Ο Κανόνας BP (2)

- Για το εσωτερικό στρώμα $l < L$
  - *Υπολογισμός* $\delta_i(l)$ → προώθηση προς τα πίσω (backward phase)

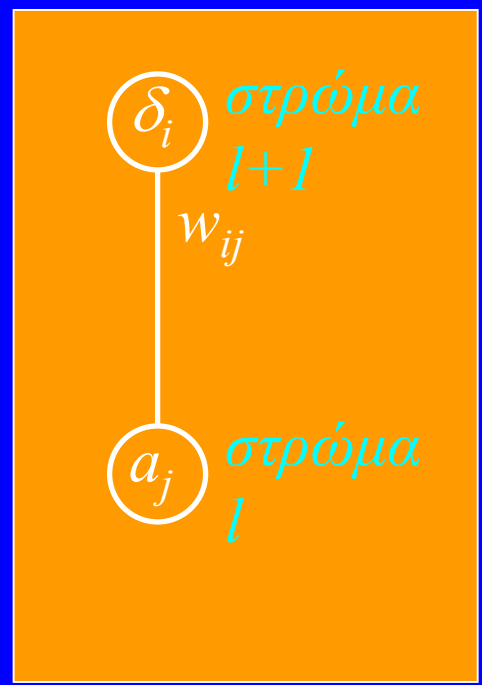


Ο Κανόνας BP (3)

- Για το εσωτερικό στρώμα $l < L$ (*συνέχεια*)

$$w_{ij}(k+1) = w_{ij}(k) + \beta\, \delta_i^{(k)}\, a_j^{(k)}$$
$$i = 1, \ldots, N(l)$$
$$j = 0, 1, \ldots, N(l-1)$$

$$\delta_i^{(k)}(l) = f'(u_i^{(k)}(l)) \sum_{\mu=1}^{N(l+1)} w_{\mu i}(l+1)\delta_\mu(l+1)$$



Ο Κανόνας BP (4)

Αρχικοποίησε τα βάρη $w_{ij}(l)$ σε μικρές τυχαίες τιμές

Για κάθε εποχή = 1, 2, …, MAXepoch {

Για κάθε πρότυπο $p = 1, \ldots, P$ {

/ Φάση ανάκλησης = Forward phase */*

/ Φάση υπολογισμού δ = Backward phase */*

/ Φάση ενημέρωσης βαρών = Update phase */*

}

} *Μέχρι* το συνολικό σφάλμα J σε μια εποχή να είναι μικρότερο από κάποιο κατώφλι ΜΙΝJ

Εφαρμογή και Προβλήματα

- Δυνατότητα επίλυσης πολύπλοκων προβλημάτων
- Κατάβαση Δυναμικού → Πρόβλημα τοπικών ελαχίστων
- Αργή σύγκλιση
- Επιλογή β

Παραλλαγές BP

- Χρήση ορμής (momentum)

$$\Delta w_{ij}(k+1) = -\beta \frac{\partial J}{\partial w_{ij}(k)} + \alpha \, \Delta w_{ij}(k)$$

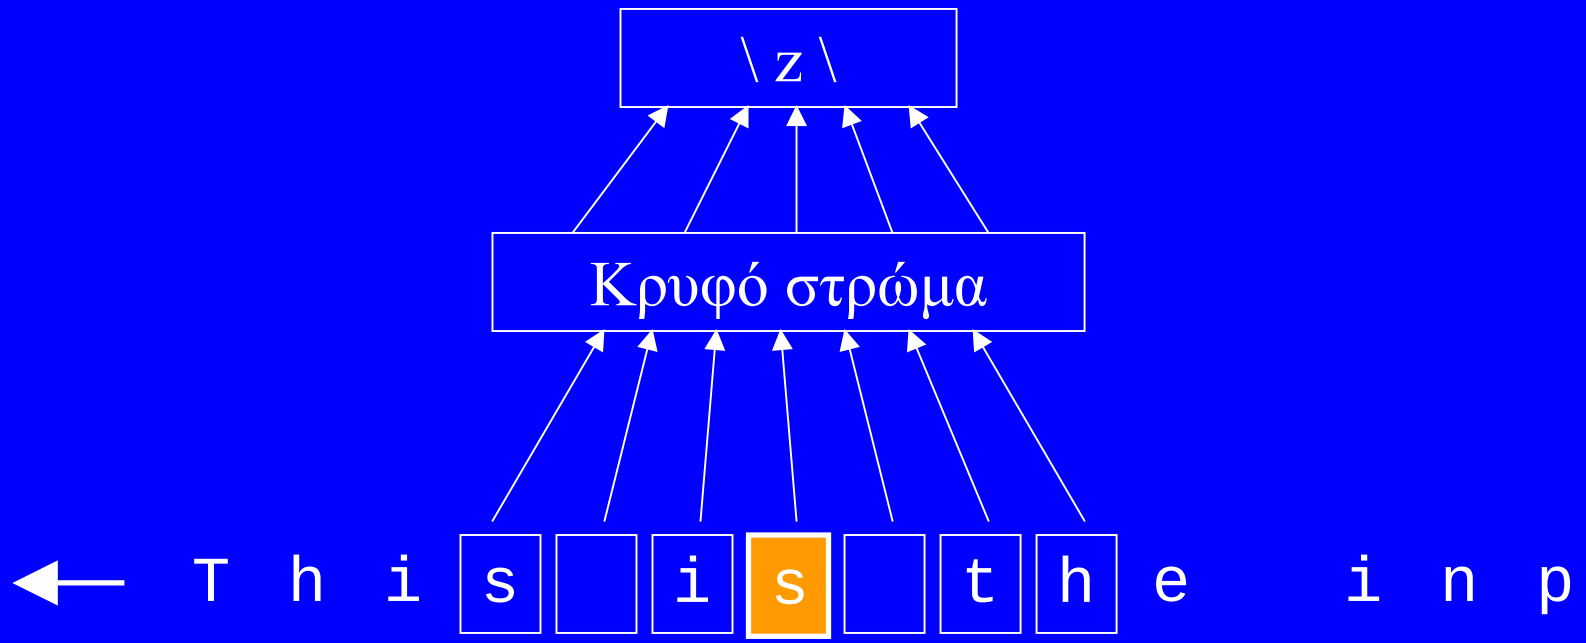
- Χρήση line search

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \lambda \, \mathbf{d}$$

- Χρήση παραγώγων δευτέρου βαθμού (Hessian)

Εφαρμογές

- Text-To-Speech (NetTalk)



Εφαρμογές (2)
NetTalk

- 7x29 είσοδοι, κωδικοποιούν 7 διαδοχικούς χαρακτήρες + σημεία στίξης
- 80 κρυφοί νευρώνες
- 26 έξοδοι κωδικοποιούν φωνήματα
- Εκπαίδευση 1024 λέξεις
- 95% ακρίβεια μετά από 50 εποχές
- Γενίκευση 78% άγνωστο κείμενο

Εφαρμογές (3)
Αναγνώριση χειρόγραφων χαρακτήρων

Αναγνώριση ταχ. Κωδικών ΗΠΑ (zip codes)

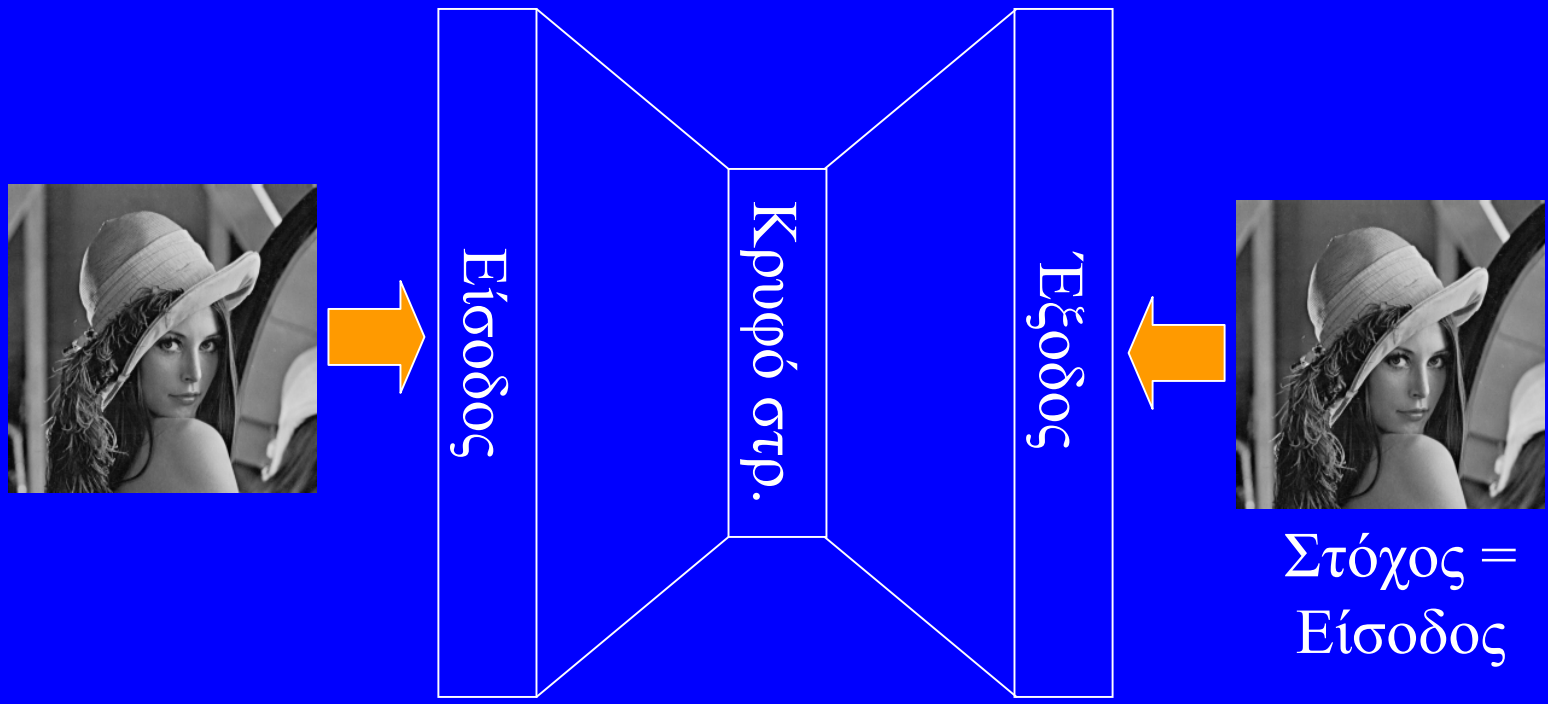
- 4 στρώματα + στρώμα εισόδου
- Είσοδος = εικόνα 16x16
- Στρώμα 1+2 = feature extraction
- Στρώμα 3 = 30 νευρώνες πλήρως συνδεδ.
- Στρώμα 4 = 10 νευρώνες εξόδου

Εφαρμογές (4)
Αναγνώριση ZIP codes

- Σύνολο 1256 νευρώνες, 9760 παράμετροι προς εκπαίδευση.
- Εκπαίδευση με BP.
- Πρότυπα εκπαίδευσης = 7300 χειρόγραφα ψηφία, σφάλμα 1%
- Πρότυπα ελέγχου = 2000 χειρόγραφα ψηφία, σφάλμα 5%

Εφαρμογές (5)

- Συμπίεση εικόνων



Εφαρμογές (6)

- Τάβλι
- Πλοήγηση οχήματος
- Αναγνώριση ομιλίας
- Συλλαβισμός λέξεων
- Αναγνώριση πλαστών συνδιαλλαγών
- Εκτίμηση τιμών μετοχών
- κλπ